

پایان نامه کارشناسی مهندسی کامپیوتر

تشخیص نوع ناهنجاری در ویدیوهای نظارتی

یادگیری چندنمونه‌ای ضعیف نظارت با ستون فقرات ترنسفورمر ویدیویی

ماکرو F1 نهایی

0.4298

از خط پایه 0.2975

دانشگاه صنعتی همدان * گروه مهندسی کامپیوتر

صورت مسئله

فصل اول

مسئله متداول: تشخیص ناهنجاری

آیا این ویدیو ناهنجار است؟
جواب: بله یا خیر

مسئله ما: تشخیص نوع ناهنجاری

کدام نوع ناهنجاری رخ داده؟
جواب: یکی از ۱۴ کلاس

چرا این تفاوت مهم است

- پاسخ عملیاتی به تصادف رانندگی، آمبولانس است؛ به سرقت مسلحانه، نیروی مسلح.
- یک هشدار خام «ناهنجاری رخ داد» برای اپراتور قابل اقدام نیست.
- از نظر دشواری، مسئله چهارده کلاسه با نسخه دودویی قابل مقایسه نیست.

مجموعه داده UCF-Crime

داده

1900

کل ویدیوها

14

کلاس

1895

رمزگشایی موفق

5

فایل خراب

ویژگی‌های داده

- ویدیوی واقعی دوربین مدار بسته، نه صحنه‌پردازی
- وضوح پایین، نور ضعیف، زاویه نامناسب
- مدتزمان از چند ثانیه تا چند دقیقه
- برچسب فقط در سطح کل ویدیو

چالش اصلی: نامتوازنی شدید

- کلاس عادی حدود نیمی از داده آموزش است
- کلاس تیراندازی کمتر از دو درصد
- در آزمون، هفت کلاس پنج ویدیو یا کمتر دارند
- کلاس Assault تنها سه ویدیوی آزمون دارد

پروتکل تقسیم داده — مسیر اول

X-CLIP

تفکیک ۷۰ به ۱۵ به ۱۵ طبقه‌ای روی کل مجموعه، سپس متوازن‌سازی مجموعه آموزش با بیش‌نمونه‌برداری کلاس‌های اقلیت.

مجموعه آموزش	کلاس
420	Normal
140	Burglary
140	RoadAccidents
140	Robbery
140	Shooting
140	Stealing
140	Vandalism
105	Abuse
105	Arrest
105	Arson
105	Assault
105	Explosion
105	Fighting
105	Shoplifting

1995

اندازه‌ی مؤثر مجموعه آموزش

296

اندازه‌ی مجموعه آزمون

مجموعه آزمون	کلاس
148	Normal
23	RoadAccidents
23	Robbery
15	Burglary
15	Stealing
8	Abuse
8	Arrest
8	Arson
8	Assault
8	Explosion
8	Fighting
8	Shooting
8	Shoplifting
8	Vandalism

اعداد ستون آموزش تعداد نمونه‌های ارائه‌شده به بهینه‌ساز است، نه تعداد ویدیوی یکتا؛ کلاس‌های کم‌بسامد با جایگذاری بیش‌نمونه‌برداری شده‌اند.

پروتکل تقسیم داده — مسیر دوم

VideoMAE

تفکیک استاندارد مرجع مجموعه‌ی UCF-Crime، بدون بازنمونه‌گیری و بدون متوازن‌سازی.

کلاس	مجموعه آموزش
Normal	800
Robbery	145
RoadAccidents	127
Stealing	95
Burglary	87
Abuse	48
Assault	47
Arrest	45
Fighting	45
Vandalism	45
Arson	41
Explosion	29
Shoplifting	29
Shooting	27

1610

اندازه‌ی مجموعه آموزش

290

اندازه‌ی مجموعه آزمون

کلاس	مجموعه آزمون
Normal	150
RoadAccidents	23
Shooting	23
Explosion	21
Shoplifting	21
Burglary	13
Arson	9
Arrest	5
Fighting	5
Robbery	5
Stealing	5
Vandalism	4
Abuse	3
Assault	3

ردیف‌های مشخص‌شده هفت کلاسی هستند که پشتیبان آماری آن‌ها در مجموعه‌ی آزمون پنج نمونه یا کمتر است؛ منشأ اصلی واریانس معیار ماکرو.

صورت‌بندی یادگیری چندنمونه‌ای

چارچوب

نظارت در سطح کیف: برچسب تنها برای کل ویدیو موجود است و هیچ حاشیه‌نویسی زمانی در مجموعه‌ی آموزش وجود ندارد.

تعریف صوری

هر ویدیو یک کیف است:

$$X = \{ x_1, \dots, x_T \}, \quad x_t \in \mathbb{R}^D, \quad T = 16, D = 1024$$

برچسب کیف $Y \in \{ 0, \dots, 13 \}$ و فرض استاندارد چندنمونه‌ای:

$$Y \neq 0 \iff \exists t \text{ نمونه‌ی } x_t \text{ حامل رویداد کلاس } Y \text{ است}$$

تجمیع و تابع زیان

شواهد ناهنجاری هر نمونه:

$$s_t = 1 - P(\text{Normal} | x_t)$$

انتخاب k نمونه‌ی برتر و تجمیع میانگین:

$$K = \text{argtop-}k \{ s_t \}, \quad z = (1/k) \sum_{t \in K} f(x_t)$$

زیان با وزن کلاس و دو جمله‌ی تنظیم:

$$L = \text{CE}(z, Y; w) + \lambda_s \sum (a_{t+1} - a_t)^2 + \lambda_p \sum a_t$$

سهم روش‌شناختی این پژوهش

در فرمول‌بندی دودویی، انتخاب نمونه‌های برتر روی یک کانال انجام می‌شود. در تعمیم چهارده‌کلاسه، اعمال مستقل آن بر هر کانال سبب می‌شود کانال کلاس عادی از عادی‌ترین نمونه‌های یک کیف ناهنجار ساخته شود و نوفه‌ی برچسب سامانمند وارد آموزش گردد. ما رتبه‌بندی را یک بار بر پایه‌ی s_t انجام می‌دهیم و همان زیرمجموعه را برای تمام کانال‌ها به کار می‌بریم.

مسیر اول

X-CLIP

تبدیل کد UMIL از دودویی به چهارده‌کلاسه

0.3327 ← 0.3881

X-CLIP چطور کار می‌کند

مسیر اول

1 CLIP روی جفت عکس و متن آموزش دیده

عکس و توضیحش در یک فضای مشترک نزدیک هم می‌افتند

1

2 طبقه‌بندی بدون آموزش

اسم هر کلاس به بردار تبدیل می‌شود و نزدیک‌ترین برنده است

2

3 X-CLIP بخش زمانی اضافه می‌کند

حالا ورودی ویدیو است، نه یک عکس تنها

3

4 در پروژه ما

بردار ویدیو با ۱۴ بردار متنی مقایسه می‌شود

4

آن ۱۴ بردار متنی نقش وزن‌های طبقه‌بند را بازی می‌کنند و هرگز آموزش نمی‌بینند.

سه اشکال بنیادی که پیدا و اصلاح شد

مسیر اول

1

میانگین‌گیری در ارزیابی

احتمال هر ۱۶ قطعه میانگین گرفته می‌شد. در ویدیوی ناهنجار، قطعه‌های عادی شواهد را خفه می‌کردند و تقریباً همه چیز عادی پیش‌بینی می‌شد.

اصلاح: تصمیم دومرحله‌ای با بیشینه

2

فایل نمرات کهنه

کد هر فایل نمرات موجود را بازاستفاده می‌کرد. در یک گزارش، ۲۸۸ ویدیو از ۲۹۸ کنار گذاشته شده و عدد روی ده ویدیو حساب شده بود.

اصلاح: بازمحاسبه پیش‌فرض

3

انتخاب قطعه برتر به تفکیک کلاس

کانال عادی از عادی‌ترین قطعه‌های یک ویدیوی سرقت ساخته می‌شد. نویز برجسته سیستماتیک وارد آموزش می‌شد.

اصلاح: یک رتبه‌بندی برای همه کلاس‌ها

تصمیم دومرحله‌ای

مسیر اول

مرحله دوم: کدام نوع؟

رای‌گیری میانگین چهار قطعه برتر، تنها میان ۱۳ کلاس ناهنجار

کلاس عادی در این مرحله اصلاً وارد رقابت نمی‌شود

مرحله اول: آیا ناهنجار است؟

بیشینه روی ۱۶ قطعه از مقدار «۱ منهای احتمال عادی»، در مقایسه با آستانه ۰٫۵

چرا بیشینه و نه میانگین: یک قطعه مشکوک کافی است، چون رویداد فقط چند ثانیه است

مثال عددی: ویدیوی سرقت، رویداد در قطعه‌های ۴ و ۵

تصمیم	در برابر آستانه ۰٫۵	نمره	روش
عادی — غلط	زیر آستانه	0.26	میانگین‌گیری روی ۸ قطعه
ناهنجار — درست	بالای آستانه	0.85	بیشینه روی همان ۸ قطعه

کلاسی که مدل یاد گرفت هرگز نگوید

مسیر اول

به جای شمردن پیش‌بینی‌های درست، شمردیم مدل هر کلاس را چند بار پیش‌بینی می‌کند.

نسبت	چند بار پیش‌بینی شد	ویدیوی واقعی	کلاس
0.25	2	8	Fighting — درگیری
0.38	3	8	Assault — تعرض
0.62	5	8	Vandalism — تخریب
1.33	20	15	Stealing — دزدی
1.70	39	23	RoadAccidents — تصادف

تشخیص

مدل روی درگیری شکست نخورده بود. یاد گرفته بود هرگز نگوید درگیری، چون گفتنش شرط‌بندی بدی بود.

علت ریشه‌ای

- تابع وزن‌دهی کلاس در کد وجود داشت ولی هیچ‌جا صدا زده نمی‌شد.
- وزن‌ها همه‌جا ۱٫۰ بودند؛ کلاس عادی حدود ۱۹ برابر کلاس درگیری گرادیان تولید می‌کرد.
- با وزن‌دهی معکوس فراوانی آن نسبت به ۳٫۶ رسید و درگیری ۹ بار پیش‌بینی شد به جای ۲ بار.

محدودیت بنیادی: هندسه فضای متنی

مسیر اول

اسم خام کلاس‌ها در فضای زبانی CLIP تقریباً هم‌راستا هستند و سقفی مستقل از کیفیت تصویری تحمیل می‌کنند.

شباهت کسینوسی	جفت کلاس
0.91	Abuse / Stealing
0.91	Assault / Arrest
0.90	Fighting / Shooting
0.83	میانگین همه جفت‌ها

آزمایش تعیین‌کننده

فرض کنید بخش تصویری کاملاً بی‌نقص باشد، یعنی بردار ویدیو دقیقاً برابر بردار کلاس خودش. در این حالت آرمانی، احتمال کلاس درست تنها ۰,۴۴ درمی‌آید.

راه حل: توصیف بصری به جای اسم حقوقی

پیش از تغییر

"Burglary"

سقف اندازه‌گیری شده: 0.44

پس از تغییر

"a burglar climbing through a broken window"

سقف اندازه‌گیری شده: 0.86

نتایج مسیر اول

مسیر اول

صحت کلی	صحت نوع	ماکرو F1	AUC دودویی	پیکربندی
0.6385	0.3716	0.3327	0.9473	اجرای پایه — اسم خام، وزن دستی
0.6351	0.4054	0.3713	0.9637	توصیف بصری + وزن معکوس فراوانی
0.6419	0.4257	0.3881	0.9629	افزودن چهار نمای زمانی در آزمون

کلاس‌هایی که از مرگ برگشتند

F1 پس از تغییر	F1 پیش از تغییر	کلاس
0.556	0.000	Arrest — بازداشت
0.714	0.462	Abuse — سوءاستفاده
0.350	0.200	Stealing — دزدی
0.167	0.000	Vandalism — تخریب

چرا از این مسیر فاصله گرفتیم

- هر پیکربندی حدود ۱۶ ساعت طول می‌کشید
- با این هزینه، آزمون سیستماتیک فرضیه‌ها ناممکن بود
- خطای باقی‌مانده در خوشه دزدی بود و ماهیتش مکانی بود، نه زمانی

مسیر دوم

VideoMAE

رمزگذار منجمد و ویژگی‌های ذخیره‌شده

0.2975 ← 0.4298

VideoMAE چطور یاد گرفت

مسیر دوم

پوشاندن

1

حدود ۹۰ درصد مکعب‌های فضازمانی پوشانده می‌شوند

بازسازی

2

رمزگذار فقط ۱۰ درصد باقی‌مانده را می‌بیند و رمزگشا جای خالی‌ها را حدس می‌زند

بدون برچسب

3

خود ویدیو هم سؤال است و هم جواب، پس روی حجم عظیمی از داده ممکن است

دور انداختن رمزگشا

4

پس از پیش‌آموزش تنها رمزگذار می‌ماند و روی Kinetics تنظیم می‌شود

تفاوت با X-CLIP

X-CLIP از متن یاد گرفت.

VideoMAE از خود ویدیو.

پس VideoMAE اصلاً کلمه نمی‌شناسد و آن سقف ۰٫۴۴ اینجا اصلاً وجود ندارد.

مهم‌ترین تصمیم پروژه: یخ زدن رمزگذار

مسیر دوم


چون رمزگذار آموزش نمی‌بیند، خروجی‌اش ثابت است. پس محاسبه مجددش در هر دوره کار تکراری محض است.

200

ارزیابی انجام‌شده

80

ثانیه برای هر آزمایش — روش جدید



16


ساعت برای هر آزمایش — روش قدیم

مورد	روش قدیم	روش جدید
رمزگشایی ویدیو	هر دوره تکرار می‌شد	یک بار، هرگز دوباره
اجرای رمزگذار	هر دوره تکرار می‌شد	یک بار، هرگز دوباره
حجم داده ورودی	۷۰ گیگابایت ویدیو	۹۳ مگابایت عدد
پارامترهای آموزش‌پذیر	حدود ۳۰۰ میلیون	۴٫۸ میلیون
زمان ۲۰۰ آزمایش	حدود ۱۳۳ روز	حدود ۴ ساعت


هزینه‌ای که پرداختیم: رمزگذار هرگز به دامنه ویدیوی نظارتی تطبیق نمی‌یابد. این را صریح گزارش کرده‌ایم.

خط لوله نهایی

مسیر دوم



مرحله اول — یک بار برای ۱۸۹۵ ویدیو، ۱۵۰ دقیقه



مرحله دوم — هر پیکربندی، ۸۰ ثانیه

تنها بخشی که ما آموزش دادیم، سر طبقه بند است: کمتر از دو درصد پارامترهای کل سیستم.

سر ترنسفورمر روی محور زمان

مسیر دوم

مشکل: قطعه تنها مبهم است

یک قطعه سه‌ثانیه‌ای داخل مغازه، در دزدی از مغازه و سرقت مسلحانه ظاهر یکسانی دارد. سر نقطه‌ای اطلاعات لازم را اصولاً در اختیار ندارد.

راه حل: خودتوجهی میان قطعه‌ها

یک جدول ۱۶ در ۱۶ می‌گوید هر قطعه چقدر به هر قطعه دیگر توجه کند. بردار جدید هر قطعه، جمع وزن دار همه قطعه‌هاست.

پیکربندی

پارامتر	مقدار
بعد پنهان	512
سرهای توجه	4
لایه‌ها	2
حذف تصادفی	0.3
پارامترها	4,772,366

نتیجه

سر طبقه‌بند	ماکرو F1، میانگین ۵ بذر
سر نقطه‌ای — خط پایه	0.3049
سر ترنسفورمر زمانی	0.3480

هر پنج بذر سر زمانی از بهترین بذر سر نقطه‌ای بالاتر بود.

ارتقای ظرفیت رمزگذار

مسیر دوم

مورد	ViT-B	ViT-L
تعداد لایه	12	24
پهنای بردار	768	1024
پارامترها	≈ 87 میلیون	≈ 300 میلیون
اندازه وصله	16 × 16	16 × 16
ماکرو F1، میانگین ۵ بذر	0.3405	0.3955
ماکرو F1، نتیجه گروهی	0.3645	0.4122

نکته‌ای که نباید اشتباه گفت

اندازه وصله در هر دو یکسان است، پس تعداد وصله‌ها فرق نمی‌کند. بهبود از ظرفیت مدل می‌آید، نه از وضوح مکانی بیشتر.

چرا این تنها بهبود قطعی پروژه است

بازه پنج بذر ViT-B

0.310 — 0.354

بازه پنج بذر ViT-L

0.370 — 0.423

آزمون من-ویتنی

p = 1 / 252

آمیزش و تنظیم لاجیت

مسیر دوم

آمیزش در فضای ویژگی

مدل تا دوره دهم زیان آموزش را تقریباً صفر می‌کند، یعنی حفظ می‌کند. ترکیب محدب دو ویدیو نمونه‌هایی می‌سازد که در داده نیستند.

تنظیم لاجیت برای دم بلند

مقداری متناسب با لگاریتم احتمال پیشین از لاجیت هر کلاس کسر می‌شود تا مرز تصمیم به سود کلاس‌های کمیاب جابه‌جا شود.


آزمایشی که شکست خورد و از آن یاد گرفتیم

اعمال خام فرمول روی هر ۱۴ کلاس، صحت را از ۰٫۶۸۹۷ به ۰٫۴۷۲ انداخت: مرحله اول تصمیم خراب می‌شد. اصلاح: محدود کردن به ۱۳ کلاس ناهنجار و مرکزی کردن.

صحت نوع	صحت	نتیجه گروهی	میانگین بنرها	پیکربندی
0.4786	0.6897	0.4122	0.3955	پایه ViT-L
0.4714	0.6793	0.4161	0.4203	آمیزش ۰٫۲
0.5000	0.6897	0.4298	0.4147	آمیزش ۰٫۲ + تنظیم لاجیت
0.4929	0.6759	0.4248	0.4135	آمیزش ۰٫۴ + تنظیم لاجیت

مسیر بهبود، گام به گام

مسیر دوم



+0.1323

بهبود مطلق ماکرو F1

+44%

بهبود نسبی

0.075

کف نوفه این مجموعه آزمون

آزمایش‌هایی که نتیجه ندادند

صداقت روش شناختی

آزمایش	نتیجه	مرجع	داوری
نمونه‌برداری سبک Kinetics با گام ۴ فریم	0.3089	0.3405	بدتر
دو برابر کردن تعداد قطعه‌ها به ۳۲	0.3875	0.3955	بدتر
الحاق ویژگی دو رمزگذار	0.3974	0.3955	درون نوفه
آموزش با یک قطعه برتر	—	—	بدون بهبود
تنظیم لاجیت به‌تنهایی	0.4114	0.3955	درون نوفه
میانگین‌گیری بنرها برای ماکرو F1	—	—	بدون بهبود
بازنویسی توصیف‌های متنی کلاس‌ها	0.74	0.86	بدتر

چرا نمونه‌برداری استاندارد بدتر شد — مهم‌ترین یافته منفی

قطعه‌های ما کشیده بودند و با نرخ نمونه‌برداری وزن‌های پیش‌آموزش‌دیده نمی‌خواندند. اصلاح آن نتیجه را بدتر کرد: قطعه‌های کشیده کل ویدیو را می‌پوشانند، در حالی که سی‌و‌دو پنجره دو ثانیه‌ای تنها حدود ۲۱ درصد یک ویدیوی طولانی را لمس می‌کنند. نتیجه: پوشش بر اعتبار قطعه غلبه دارد.

چقدر از این اعداد نوفه است؟

اعتبارسنجی آماری

مجموعه آزمون با ۴۰۰۰ بار باز نمونه‌گیری خودگردان تحلیل شد تا پراکندگی مورد انتظار تخمین زده شود.

معیار	مقدار نقطه‌ای	انحراف معیار	بازه اطمینان ۹۵ درصد
ماکرو F1	0.4298	0.037	[0.503 , 0.339]
صحت چندکلاسه	0.6897	0.027	[0.745 , 0.635]
صحت نوع ناهنجاری	0.5000	0.041	[0.585 , 0.420]
AUC دودویی	0.9610	0.011	[0.980 , 0.938]

کف نوفه

0.075

اختلاف کمتر از این مقدار در ماکرو F1 روی این تقسیم از نوفه قابل تفکیک نیست.

سقف تنظیم روی یک مجموعه آزمون کوچک

تعداد ارزیابی	تورم مورد انتظار
۸	0.069+
۵۰	0.095+
۲۰۰	0.111+

با حدود ۲۰۰ ارزیابی روی همین تقسیم، گزارش بهترین عدد مشاهده‌شده نتیجه را بیش از اندازه خود اثر بزرگ نشان می‌دهد. همه اعداد این ارائه از پیکربندی‌هایی می‌آیند که پیش از اجرا تثبیت شده بودند.

جدول کامل نتایج

جمع‌بندی نتایج

پیکربندی	رمزگذار	ماکرو F1	صحت نوع	صحت کلی	AUC
مسیر اول — اسم خام کلاس، وزن دستی	X-CLIP ViT-B/32	0.3327	0.3716	0.6385	0.9473
مسیر اول — توصیف بصری + وزن معکوس	X-CLIP ViT-B/32	0.3713	0.4054	0.6351	0.9637
مسیر اول — چهار نمای زمانی در آزمون	X-CLIP ViT-B/32	0.3881	0.4257	0.6419	0.9629
مسیر دوم — سر نقطه‌ای، خط پایه	VideoMAE ViT-B	0.2975	0.3860	0.5660	—
مسیر دوم — سر ترنسفورمر زمانی	VideoMAE ViT-B	0.3444	0.3930	0.6350	—
مسیر دوم — نرخ یادگیری ۰٫۰۰۰۳	VideoMAE ViT-B	0.3645	0.4210	0.6550	—
مسیر دوم — ارتقا به رمزگذار بزرگ	VideoMAE ViT-L	0.4122	0.4786	0.6897	—
مسیر دوم — افزودن آمیزش	VideoMAE ViT-L	0.4161	0.4714	0.6793	—
مسیر دوم — آمیزش + تنظیم لاجیت	VideoMAE ViT-L	0.4298	0.5000	0.6897	0.9610

مسیر اول روی تقسیمی با ۲۹۶ ویدیوی آزمون و مسیر دوم روی تقسیم استاندارد با ۲۹۰ ویدیو اجرا شده‌اند.

0.4298

ماکرو F1 نهایی

0.5000

صحت نوع ناهنجاری

0.6897

صحت چندکلاسه

جمع‌بندی و کارهای آینده

دست‌آورد

اصلاح سه اشکال بنیادی، بازطراحی معماری با رمزگذار منجمد، سر ترنسفورمر زمانی، و پروتکل ارزیابی با کف نوفه

محدودیت

رمزگذار به دامنه نظارتی تطبیق نمی‌یابد؛ مجموعه آزمون کوچک است و بازه‌های اطمینان پهن

کار آینده

افزایش وضوح مکانی برای خوشه دزدی، تنظیم دقیق رمزگذار روی داده نظارتی، و تقسیم داده با سهم بزرگ‌تر برای آزمون

بیشترین اثر را نه یک ایده الگوریتمی، بلکه کاهش هزینه هر آزمایش داشت؛ و کمی کردن نوفه پیش از تفسیر، از ادعاهایی جلوگیری کرد که داده پشتیبان آن‌ها نبود.