

تشخیص نوع ناهنجاری در ویدیوهای نظارتی

یادگیری چند نمونه‌ای ضعیف نظارت با ستون فقرات ترنسفورمر ویدیویی

ماکرو F1 نهایی

0.4298

از خط پایه 0.2975

صورت مسئله

مسئله ما: تشخیص نوع ناهنجاری

کدام نوع ناهنجاری رخ داده؟
جواب: یکی از ۱۴ کلاس

مسئله متداول: تشخیص ناهنجاری

آیا این ویدیو ناهنجار است؟
جواب: بله یا خیر

چرا این تفاوت مهم است

- پاسخ عملیاتی به تصادف رانندگی، آمبولانس است؛ به سرقت مسلحانه، نیروی مسلح.
- یک هشدار خام «ناهنجاری رخ داد» برای اپراتور قابل اقدام نیست.
- از نظر دشواری، مسئله چهارده کلاسه با نسخه دودویی قابل مقایسه نیست.

مجموعه داده UCF-Crime

1900

کل ویدیوها

14

کلاس

1895

رمزگشایی موفق

5

فایل خراب

ویژگی‌های داده

- ویدیوی واقعی دوربین مداربسته، نه صحنه‌پردازی
- وضوح پایین، نور ضعیف، زاویه نامناسب
- مدتزمان از چند ثانیه تا چند دقیقه
- برچسب فقط در سطح کل ویدیو

چالش اصلی: نامتوازنی شدید

- کلاس عادی حدود نیمی از داده آموزش است
- کلاس تیراندازی کمتر از دو درصد
- در آزمون، هفت کلاس پنج ویدیو یا کمتر دارند
- کلاس Assault تنها سه ویدیوی آزمون دارد

تعداد ویدیو در هر کلاس — مجموعه آموزش

تعداد ویدیو	کلاس
800	Normal — عادی
145	Robbery — سرقت
127	RoadAccidents — تصادف
95	Stealing — دزدی
87	Burglary — سرقت از منزل
48	Abuse — سوءاستفاده
47	Assault — تعرض

تعداد ویدیو	کلاس
45	Arrest — بازداشت
45	Fighting — درگیری
45	Vandalism — تخریب
41	Arson — آتش‌افروزی
29	Explosion — انفجار
29	Shoplifting — دزدی از مغازه
27	Shooting — تیراندازی

جمع: ۱۶۱۰ ویدیوی آموزش • ۸۰۰ عادی و ۸۱۰ ناهنجار

نسبت کلاس عادی به کمیاب‌ترین کلاس حدود ۳۰ به ۱ است. همین نسبت است که وزن‌دهی معکوس فراوانی را ضروری می‌کند.

تعداد ویدیو در هر کلاس — مجموعه آزمون

تقسیم مسیر اول	تقسیم استاندارد	کلاس
148	150	Normal — عادی
23	23	RoadAccidents — تصادف رانندگی
8	23	Shooting — تیراندازی
8	21	Explosion — انفجار
8	21	Shoplifting — دزدی از مغازه
15	13	Burglary — سرقت از منزل
8	9	Arson — آتش افروزی
8	5	Arrest — بازداشت
8	5	Fighting — درگیری
23	5	Robbery — سرقت
15	5	Stealing — دزدی
8	4	Vandalism — تخریب اموال
8	3	Abuse — سوءاستفاده
8	3	Assault — تعرض

جمع ستون دوم ۲۹۰ و جمع ستون سوم ۲۹۶ است. ردیف‌های پررنگ، هفت کلاسی هستند که پنج ویدیوی آزمون یا کمتر دارند.

290

کل مجموعه آزمون

1610

کل مجموعه آموزش

0%

همپوشانی دو مجموعه

دو تقسیم متفاوت

مسیر X-CLIP روی تقسیمی با ۲۹۶ ویدیوی آزمون اجرا شد و مسیر VideoMAE روی تقسیم استاندارد با ۲۹۰ ویدیو.

چرا ارزیابی نوفه‌آلود است

کلاس Assault تنها سه ویدیوی آزمون دارد. یک ویدیو یعنی یک‌سوم یادآوری آن کلاس، و ماکرو F1 به هر ۱۴ کلاس وزن یکسان می‌دهد.

پیش از ارائه این اعداد را با فایل تقسیم خودتان بسنجید.

نظارت ضعیف و یادگیری چندنمونه‌ای

هزینه	برچسب چیست	سطح نظارت
بسیار پرهزینه	هر فریم برچسب دارد	نظارت کامل
کم هزینه	فقط کل ویدیو برچسب دارد	نظارت ضعیف
رایگان	هیچ برچسبی نیست	بدون نظارت

مسئله ما

در یک ویدیوی سه دقیقه‌ای، سرقت شاید ۱۵ ثانیه باشد. بیش از ۹۰ درصد آنچه مدل می‌بیند، با وجود برچسب «سرقت»، عادی است.

راه حل: هر ویدیو یک کیف، هر قطعه یک نمونه

1

ویدیو به ۱۶ قطعه شکسته می‌شود

2

مدل به هر قطعه نمره می‌دهد

3

مشکوک‌ترین قطعه‌ها انتخاب می‌شوند

4

فرض: همان‌ها برچسب کیف را حمل می‌کنند

مسیر اول

X-CLIP

تبدیل کد UMIL از دودویی به چهارده‌کلاسه

0.3327 ← 0.3881

X-CLIP چطور کار می‌کند

1 CLIP روی جفت عکس و متن آموزش دیده

عکس و توضیحش در یک فضای مشترک نزدیک هم می‌افتند

1

2 طبقه‌بندی بدون آموزش

اسم هر کلاس به بردار تبدیل می‌شود و نزدیک‌ترین برنده است

2

3 X-CLIP بخش زمانی اضافه می‌کند

حالا ورودی ویدیو است، نه یک عکس تنها

3

4 در پروژه ما

بردار ویدیو با ۱۴ بردار متنی مقایسه می‌شود

4

آن ۱۴ بردار متنی نقش وزن‌های طبقه‌بند را بازی می‌کنند و هرگز آموزش نمی‌بینند.

سه اشکال بنیادی که پیدا و اصلاح شد

1

میانگین‌گیری در ارزیابی

احتمال هر ۱۶ قطعه میانگین گرفته می‌شد. در ویدیوی ناهنجار، قطعه‌های عادی شواهد را خفه می‌کردند و تقریباً همه چیز عادی پیش‌بینی می‌شد.

اصلاح: تصمیم دومرحله‌ای با بیشینه

2

فایل نمرات کهنه

کد هر فایل نمرات موجود را بازاستفاده می‌کرد. در یک گزارش، ۲۸۸ ویدیو از ۲۹۸ کنار گذاشته شده و عدد روی ده ویدیو حساب شده بود.

اصلاح: بازمحاسبه پیش‌فرض

3

انتخاب قطعه برتر به تفکیک کلاس

کانال عادی از عادی‌ترین قطعه‌های یک ویدیوی سرقت ساخته می‌شد. نویز برجسب سیستماتیک وارد آموزش می‌شد.

اصلاح: یک رتبه‌بندی برای همه کلاس‌ها

تصمیم دومرحله‌ای

مرحله دوم: کدام نوع؟

رای‌گیری میانگین چهار قطعه برتر، تنها میان ۱۳ کلاس ناهنجار

کلاس عادی در این مرحله اصلاً وارد رقابت نمی‌شود

مرحله اول: آیا ناهنجار است؟

بیشینه روی ۱۶ قطعه از مقدار «۱ منهای احتمال عادی»، در مقایسه با آستانه ۰٫۵

چرا بیشینه و نه میانگین: یک قطعه مشکوک کافی است، چون رویداد فقط چند ثانیه است

مثال عددی: ویدیوی سرقت، رویداد در قطعه‌های ۴ و ۵

تصمیم	در برابر آستانه ۰٫۵	نمره	روش
عادی — غلط	زیر آستانه	0.26	میانگین‌گیری روی ۸ قطعه
ناهنجار — درست	بالای آستانه	0.85	بیشینه روی همان ۸ قطعه

کلاسی که مدل یاد گرفت هرگز نگوید

به جای شمردن پیش‌بینی‌های درست، شمردیم مدل هر کلاس را چند بار پیش‌بینی می‌کند.

نسبت	چند بار پیش‌بینی شد	ویدیوی واقعی	کلاس
0.25	2	8	Fighting — درگیری
0.38	3	8	Assault — تعرض
0.62	5	8	Vandalism — تخریب
1.33	20	15	Stealing — دزدی
1.70	39	23	RoadAccidents — تصادف

تشخیص

مدل روی درگیری شکست نخورده بود. یاد گرفته بود هرگز نگوید درگیری، چون گفتنش شرط‌بندی بدی بود.

علت ریشه‌ای

- تابع وزن‌دهی کلاس در کد وجود داشت ولی هیچ‌جا صدا زده نمی‌شد.
- وزن‌ها همه‌جا ۱,۰ بودند؛ کلاس عادی حدود ۱۹ برابر کلاس درگیری گرادیان تولید می‌کرد.
- با وزن‌دهی معکوس فراوانی آن نسبت به ۳,۶ رسید و درگیری ۹ بار پیش‌بینی شد به جای ۲ بار.

محدودیت بنیادی: هندسه فضای متنی

اسم خام کلاس‌ها در فضای زبانی CLIP تقریباً هم‌راستا هستند و سقفی مستقل از کیفیت تصویری تحمیل می‌کنند.

جفت کلاس	شبهات کسینوسی
Abuse / Stealing	0.91
Assault / Arrest	0.91
Fighting / Shooting	0.90
میانگین همه جفت‌ها	0.83

آزمایش تعیین‌کننده

فرض کنید بخش تصویری کاملاً بی‌نقص باشد، یعنی بردار ویدیو دقیقاً برابر بردار کلاس خودش. در این حالت آرمانی، احتمال کلاس درست تنها ۰,۴۴ درمی‌آید.

راه حل: توصیف بصری به جای اسم حقوقی

پیش از تغییر

"Burglary"

سقف اندازه‌گیری شده: 0.44

پس از تغییر

"a burglar climbing through a broken window"

سقف اندازه‌گیری شده: 0.86

نتایج مسیر اول

صحت کلی	صحت نوع	ماکرو F1	AUC دودویی	پیکربندی
0.6385	0.3716	0.3327	0.9473	اجرای پایه — اسم خام، وزن دستی
0.6351	0.4054	0.3713	0.9637	توصیف بصری + وزن معکوس فراوانی
0.6419	0.4257	0.3881	0.9629	افزودن چهار نمای زمانی در آزمون

کلاس‌هایی که از مرگ برگشتند

F1 پس از تغییر	F1 پیش از تغییر	کلاس
0.556	0.000	Arrest — بازداشت
0.714	0.462	Abuse — سوءاستفاده
0.350	0.200	Stealing — دزدی
0.167	0.000	Vandalism — تخریب

چرا از این مسیر فاصله گرفتیم

- هر پیکربندی حدود ۱۶ ساعت طول می‌کشید
- با این هزینه، آزمون سیستماتیک فرضیه‌ها ناممکن بود
- خطای باقی‌مانده در خوشه دزدی بود و ماهیتش مکانی بود، نه زمانی

مسیر دوم

VideoMAE

رمزگذار منجمد و ویژگی‌های ذخیره‌شده

0.2975 ← 0.4298

VideoMAE چطور یاد گرفت

پوشاندن

1

حدود ۹۰ درصد مکعب‌های فضازمانی پوشانده می‌شوند

بازسازی

2

رمزگذار فقط ۱۰ درصد باقی‌مانده را می‌بیند و رمزگشا جای خالی‌ها را حدس می‌زند

بدون برچسب

3

خود ویدیو هم سؤال است و هم جواب، پس روی حجم عظیمی از داده ممکن است

دور انداختن رمزگشا

4

پس از پیش‌آموزش تنها رمزگذار می‌ماند و روی Kinetics تنظیم می‌شود

تفاوت با X-CLIP

X-CLIP از متن یاد گرفت.

VideoMAE از خود ویدیو.

پس VideoMAE اصلاً کلمه نمی‌شناسد و آن سقف ۰٫۴۴ اینجا اصلاً وجود ندارد.

مهم‌ترین تصمیم پروژه: یخ زدن رمزگذار


چون رمزگذار آموزش نمی‌بیند، خروجی‌اش ثابت است. پس محاسبه مجددش در هر دوره کار تکراری محض است.

200

ارزیابی انجام‌شده

80

ثانیه برای هر آزمایش — روش جدید




16

ساعت برای هر آزمایش — روش قدیم


مورد	روش قدیم	روش جدید
رمزگشایی ویدیو	هر دوره تکرار می‌شد	یک بار، هرگز دوباره
اجرای رمزگذار	هر دوره تکرار می‌شد	یک بار، هرگز دوباره
حجم داده ورودی	۷۰ گیگابایت ویدیو	۹۳ مگابایت عدد
پارامترهای آموزش‌پذیر	حدود ۳۰۰ میلیون	۴,۸ میلیون
زمان ۲۰۰ آزمایش	حدود ۱۳۳ روز	حدود ۴ ساعت

هزینه‌ای که پرداختیم: رمزگذار هرگز به دامنه ویدیوی نظارتی تطبیق نمی‌یابد. این را صریح گزارش کرده‌ایم.

خط لوله نهایی



مرحله اول — یک بار برای ۱۸۹۵ ویدیو، ۱۵۰ دقیقه



مرحله دوم — هر پیکربندی، ۸۰ ثانیه

تنها بخشی که ما آموزش دادیم، سر طبقه‌بند است: کمتر از دو درصد پارامترهای کل سیستم.

سر ترنسفورمر روی محور زمان

مشکل: قطعه تنها مبهم است

یک قطعه سه‌ثانیه‌ای داخل مغازه، در دزدی از مغازه و سرقت مسلحانه ظاهر یکسانی دارد. سر نقطه‌ای اطلاعات لازم را اصولاً در اختیار ندارد.

راه حل: خودتوجهی میان قطعه‌ها

یک جدول ۱۶ در ۱۶ می‌گوید هر قطعه چقدر به هر قطعه دیگر توجه کند. بردار جدید هر قطعه، جمع وزن‌دار همه قطعه‌هاست.

پیکربندی

پارامتر	مقدار
بعد پنهان	512
سرهای توجه	4
لایه‌ها	2
حذف تصادفی	0.3
پارامترها	4,772,366

نتیجه

سر طبقه‌بند	ماکرو F1، میانگین ۵ بذر
سر نقطه‌ای — خط پایه	0.3049
سر ترنسفورمر زمانی	0.3480

هر پنج بذر سر زمانی از بهترین بذر سر نقطه‌ای بالاتر بود.

ارتقای ظرفیت رمزگذار

مورد	ViT-B	ViT-L
تعداد لایه	12	24
پهنای بردار	768	1024
پارامترها	≈ 87 میلیون	≈ 300 میلیون
اندازه وصله	16 × 16	16 × 16
ماکرو F1، میانگین ۵ بذر	0.3405	0.3955
ماکرو F1، نتیجه گروهی	0.3645	0.4122

نکته‌ای که نباید اشتباه گفت

اندازه وصله در هر دو یکسان است، پس تعداد وصله‌ها فرق نمی‌کند. بهبود از ظرفیت مدل می‌آید، نه از وضوح مکانی بیشتر.

چرا این تنها بهبود قطعی پروژه است

بازه پنج بذر ViT-B

0.310 — 0.354

بازه پنج بذر ViT-L

0.370 — 0.423

آزمون من-ویتنی

p = 1 / 252

آمیزش و تنظیم لاجیت

آمیزش در فضای ویژگی

مدل تا دوره دهم زیان آموزش را تقریباً صفر می‌کند، یعنی حفظ می‌کند. ترکیب محدب دو ویدیو نمونه‌هایی می‌سازد که در داده نیستند.

تنظیم لاجیت برای دم بلند


مقداری متناسب با لگاریتم احتمال پیشین از لاجیت هر کلاس کسر می‌شود تا مرز تصمیم به سود کلاس‌های کمیاب جابه‌جا شود.

آزمایشی که شکست خورد و از آن یاد گرفتیم

اعمال خام فرمول روی هر ۱۴ کلاس، صحت را از ۰٫۶۸۹۷ به ۰٫۴۷۲ انداخت: مرحله اول تصمیم خراب می‌شد. اصلاح: محدود کردن به ۱۳ کلاس ناهنجار و مرکزی کردن.

صحت نوع	صحت	نتیجه گروهی	میانگین بنرها	پیکربندی
0.4786	0.6897	0.4122	0.3955	پایه ViT-L
0.4714	0.6793	0.4161	0.4203	آمیزش ۰٫۲
0.5000	0.6897	0.4298	0.4147	آمیزش ۰٫۲ + تنظیم لاجیت
0.4929	0.6759	0.4248	0.4135	آمیزش ۰٫۴ + تنظیم لاجیت

مسیر بهبود، گام به گام



+0.1323

بهبود مطلق ماکرو F1

+44%

بهبود نسبی

0.075

کف نوفه این مجموعه آزمون

آزمایش‌هایی که نتیجه ندادند

دآوری	مرجع	نتیجه	آزمایش
بدتر	0.3405	0.3089	نمونه‌برداری سبک Kinetics با گام ۴ فریم
بدتر	0.3955	0.3875	دو برابر کردن تعداد قطعه‌ها به ۳۲
درون نوفه	0.3955	0.3974	الحاق ویژگی دو رمزگذار
بدون بهبود	—	—	آموزش با یک قطعه برتر
درون نوفه	0.3955	0.4114	تنظیم لاجیت به‌تنهایی
بدون بهبود	—	—	میانگین‌گیری بنرها برای ماکرو F1
بدتر	0.86	0.74	بازنویسی توصیف‌های متنی کلاس‌ها

چرا نمونه‌برداری استاندارد بدتر شد — مهم‌ترین یافته منفی

قطعه‌های ما کشیده بودند و با نرخ نمونه‌برداری وزن‌های پیش‌آموزش‌دیده نمی‌خواندند. اصلاح آن نتیجه را بدتر کرد: قطعه‌های کشیده کل ویدیو را می‌پوشانند، در حالی که سی‌ودو پنجره دو ثانیه‌ای تنها حدود ۲۱ درصد یک ویدیوی طولانی را لمس می‌کنند.

نتیجه: پوشش بر اعتبار قطعه غلبه دارد.

چقدر از این اعداد نوفه است؟

مجموعه آزمون با ۴۰۰۰ بار بازنمونه‌گیری خودگردان تحلیل شد تا پراکندگی مورد انتظار تخمین زده شود.

بازه اطمینان ۹۵ درصد	انحراف معیار	مقدار نقطه‌ای	معیار
[0.503 , 0.339]	0.037	0.4298	ماکرو F1
[0.745 , 0.635]	0.027	0.6897	صحت چندکلاسه
[0.585 , 0.420]	0.041	0.5000	صحت نوع ناهنجاری
[0.980 , 0.938]	0.011	0.9610	AUC دودویی

کف نوفه

0.075

اختلاف کمتر از این مقدار در ماکرو F1 روی این تقسیم از نوفه قابل تفکیک نیست.

سقف تنظیم روی یک مجموعه آزمون کوچک

تورم مورد انتظار	تعداد ارزیابی
0.069+	۸
0.095+	۵۰
0.111+	۲۰۰

با حدود ۲۰۰ ارزیابی روی همین تقسیم، گزارش بهترین عدد مشاهده‌شده نتیجه را بیش از اندازه خود اثر بزرگ نشان می‌دهد. همه اعداد این ارائه از پیکربندی‌هایی می‌آیند که پیش از اجرا تثبیت شده بودند.

جدول کامل نتایج

پیکربندی	رمزگذار	ماکرو F1	صحت نوع	صحت کلی	AUC
مسیر اول — اسم خام کلاس، وزن دستی	X-CLIP ViT-B/32	0.3327	0.3716	0.6385	0.9473
مسیر اول — توصیف بصری + وزن معکوس	X-CLIP ViT-B/32	0.3713	0.4054	0.6351	0.9637
مسیر اول — چهار نمای زمانی در آزمون	X-CLIP ViT-B/32	0.3881	0.4257	0.6419	0.9629
مسیر دوم — سر نقطه‌ای، خط پایه	VideoMAE ViT-B	0.2975	0.3860	0.5660	—
مسیر دوم — سر ترنسفورمر زمانی	VideoMAE ViT-B	0.3444	0.3930	0.6350	—
مسیر دوم — نرخ یادگیری ۰٫۰۰۰۳	VideoMAE ViT-B	0.3645	0.4210	0.6550	—
مسیر دوم — ارتقا به رمزگذار بزرگ	VideoMAE ViT-L	0.4122	0.4786	0.6897	—
مسیر دوم — افزودن آمیزش	VideoMAE ViT-L	0.4161	0.4714	0.6793	—
مسیر دوم — آمیزش + تنظیم لاجیت	VideoMAE ViT-L	0.4298	0.5000	0.6897	0.9610

مسیر اول روی تقسیمی با ۲۹۶ ویدیوی آزمون و مسیر دوم روی تقسیم استاندارد با ۲۹۰ ویدیو اجرا شده‌اند.

0.4298

ماکرو F1 نهایی

0.5000

صحت نوع ناهنجاری

0.6897

صحت چندکلاسه

جمع‌بندی و کارهای آینده

دست‌آورد

اصلاح سه اشکال بنیادی، بازطراحی معماری با رمزگذار منجمد، سر ترنسفورمر زمانی، و پروتکل ارزیابی با کف نوفه

محدودیت

رمزگذار به دامنه نظارتی تطبیق نمی‌یابد؛ مجموعه آزمون کوچک است و بازه‌های اطمینان پهن

کار آینده

افزایش وضوح مکانی برای خوشه دزدی، تنظیم دقیق رمزگذار روی داده نظارتی، و تقسیم داده با سهم بزرگ‌تر برای آزمون

بیشترین اثر را نه یک ایده الگوریتمی، بلکه کاهش هزینه هر آزمایش داشت؛ و کمی کردن نوفه پیش از تفسیر، از ادعاهایی جلوگیری کرد که داده پشتیبان آن‌ها نبود.